


# Ensemble

# Ensemble

- 여러 개의 예측모형들을 결합하여 하나의 예측 모형을 만드는 방법

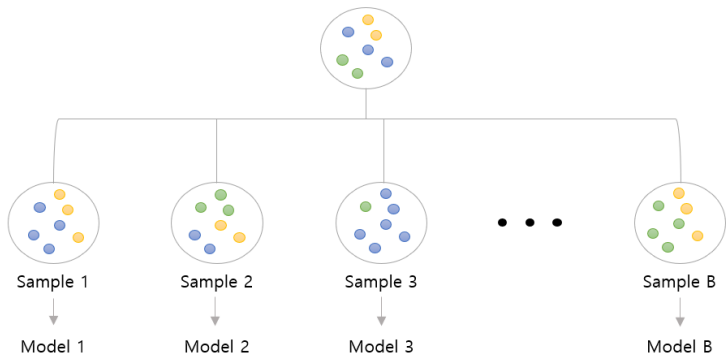


- The bootstrap is a flexible and powerful statistical tool that can be used to quantify the uncertainty associated with a given estimator or statistical learning method.
- For example, it can provide an estimate of the standard error of a coefficient, or a confidence interval for that coefficient.
- The "bootstrap data sets" is created by sampling with replacement, and is the same size as our original data set.

# Bagging

- Bagging (Bootstrap aggregation)

- Bootstrap을 이용하여 모형을 생성



# Bagging - 알고리즘

-  $L = \{(x_i, y_i)\}_{i=1}^n$  : training data

1. For  $b = 1, \dots, B$

1) 부스트랩  $L^{*(b)}$  샘플 생성

2) 각 샘플에 대하여 예측 모형  $f^{(b)}(x)$  구축

2.  $B$ 개의 예측 모형 결합 : 최종모형  $\hat{f}(x)$  구축

- 회귀모형 :  $\hat{f}(x) = \frac{1}{B} \sum_{b=1}^B f^{(b)}(x)$

- 분류모형 :  $B$ 개중 가장 많이 분류된 범주로 분류

# Bagging

- 평균을 사용하여 불안정한 예측모형의 분산 감소
- 일부러 과적합된 예측모형에 bagging을 적용하였을 때 효과 증가
- Bagging은 여러 예측모형에 대해 유용한 방법이지만, 특히 의사결정나무에 유용하게 사용될 수 있음
- 개별 트리는 분산은 크고 편차는 작지만,  $B$ 개의 트리의 결과를 평균을 하게 되면 분산을 줄이면서 예측력을 향상 시킬 수 있음
- Bagging은 최적의 트리를 구축하는 것보다 더 빠를 수도 있음 (가지치기 등의 모형 선택 단계 생략 가능)


# Out-of-Bag Error Estimation

- 배깅모형에서 test error를 계산하는 방법
- bootstrap sample을 추출하면 평균적으로 원래 데이터의 2/3 정도만 선택됨

$$\lim_{n \rightarrow \infty} \left( \frac{n-1}{n} \right)^n = \lim_{n \rightarrow \infty} \left( 1 - \frac{1}{n} \right)^n = e^{-1} = 0.368$$

- 선택되지 않는 나머지 데이터를 out-of-bag(OOB) 관측값이라고 함
- 이 OOB 관측값을 이용하여 test error를 계산할 수 있음

# Bagging the Heart Data






# Random Forest

- bootstrap sample + random sample of  $m$  predictors
- 전체적인 방법은 bagging과 동일
- 하나의 트리를 형성하는 과정에서, 각 노드에서 전체  $p$ 개의 설명변수 중  $m$ 개만을 임의로 추출하여 분리 규칙 생성
- 일반적으로  $m \approx \sqrt{p}$
- 분리에 사용하는 설명변수를 무작위로 선택함으로써 트리 사이의 상관성을 줄여 앙상블의 효과를 향상 시킬 수 있음 (분산 감소)

# Random Forest



# Random Forest

- 예측력은 Boosting과 비슷
- 분리규칙을 생성할 때 사용하는 변수의 숫자가 훨씬 작아지기 때문에 효율성이 높고, 배깅/부스팅보다 속도가 빠름
- 트리의 장점 : 설명력, 단점 : 정확도가 떨어짐
- 랜덤포레스트는 많은 수의 트리를 생성하기 때문에 예측력을 향상시킬 수 있지만, 트리의 강점이 사라짐
- 대신, 변수의 중요도를 측정할 수 있음

# 변수중요도

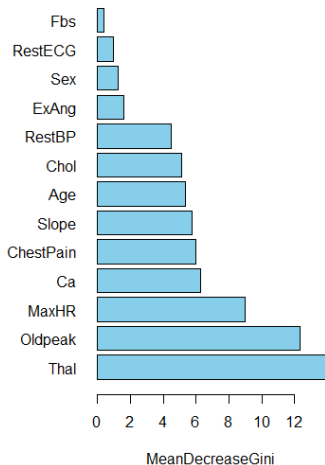

- 정확도 감소

- ▶  $b$ 번째 트리 형성  $\rightarrow$  OOB error 측정( $e_b$ )  $\rightarrow$  OOB에서 변수  $X_i$ 를 임의로 섞음, OOB error 측정( $r_i$ ),  $i = 1, \dots, p$
- ▶  $d_i = r_i - e_b$ ,  $b = 1, \dots, B \Rightarrow$  변수중요도  $= \bar{d}_i / s_{d_i}$

- 불순도 감소


- ▶ 트리 형성 과정에서 분리 규칙으로 사용된 변수들에 대해 RSS나 불순도가 얼마나 감소했는지를 모든  $B$ 개의 트리에서 측정하여 평균한 값을 변수 중요도로 사용

# 변수중요도



# Boosting

- 약한(weak) 예측 모델을 결합하여 매우 정확한 예측 모델을 만드는 방법
- 예측모형을 순차적으로(sequentially) 학습하여 먼저 학습된 모형의 결과가 다음 모형의 학습에 정보를 제공
- 이전 모형의 결점을 보완하는 방향으로 학습이 이루어짐



# AdaBoost : Adaptive Boosting(1997)


1. 초기가중치설정 :  $w_i = 1/n, i = 1, \dots, n$
2. 다음을  $b = 1, \dots, B$  만큼 반복
  - 2.1 가중치  $w_i$ 를 이용하여 bootstrap sample 추출하여 분류 모형  $f_b(x) \in \{-1, 1\}$  생성 ( $y_i \in \{-1, 1\}$ )
  - 2.2 오차를 계산 :  $err_b = \frac{\sum_{i=1}^n w_i I(y_i \neq f_b(x_i))}{\sum_{i=1}^n w_i}$
  - 2.3  $\alpha_b = \log \frac{1 - err_b}{err_b}$
  - 2.4 가중치 갱신 :  $w_i \leftarrow w_i \times \exp(\alpha_b I(y_i \neq f_b(x_i)))$
3. 최종모형 결정 :  $f(x) = \text{sign} \left( \sum_{b=1}^B \alpha_b f_b(x) \right)$

# Boosting

- 예측력이 매우 좋음
- Bagging과는 달리 과적합할 가능성이 있음 ( $B$  선택 중요)
- 약한 예측모형을 기본 모형으로 사용하는 게 적합하기 때문에 decision stump (하나의 분할을 갖는 트리, 즉 terminal node의 갯수 = 2)를 많이 사용함
- 물론 기본 예측 모형으로 분할이 몇 번 일어난 모형을 사용할지 선택 가능



# Example



# Bagging vs. Boosting

| 비교       | Bagging         | Boosting                                |
|----------|-----------------|---|
| 특징       | 병렬 앙상블 모델       | 연속 앙상블                                  |
| 목적       | variance 감소     | bias 감소                                 |
| 적합한 모형   | High variance   | Low variance                            |
|          | Low bias        | High bias                               |
| 대표 알고리즘  | Random Forest   | Adaboost                                |
|          |                 | Gradient Boosting                       |
| Sampling | Random sampling | Random sampling<br>with weight on error |